

Gaspar dentro de MAGI: estado ejecutivo y validacion 24M

Informe orientado a decision tecnica. Gaspar evalua calidad de oportunidad de entrada; no predice direccion ni usa indicadores de Baltasar.

1. Resumen ejecutivo

Gaspar ya cuenta con un flujo modular completo: generacion de dataset por Bot A_sub2, contrato propio, pipeline de entrenamiento, diagnostico, targets versionados y pruebas automatizadas. El dataset de 24 meses fue auditado como de calidad alta y apto para entrenamiento serio.

Decision actual: Gaspar esta listo para analisis y backtesting serio, pero no para trading real. El baseline operativo de investigacion es **target_v2**. **target_v4** queda como challenger por mejor estabilidad temporal, pero no se promueve aun porque desplaza la dependencia hacia **daily_range_state_LATE** y todavia no hay validacion economica con resultados reales de Bot C.

148,552

Dataset normalizado
24 meses

0.8912

Baseline v2 F1 macro
accuracy 0.8809

0.8903

Challenger v4 F1
macro
accuracy 0.8949

NO

Estado trading real
falta Bot C + validacion
economica

Que funciona: carga CSV/JSONL, deduplicacion de espejo, targets v1-v4, split temporal, walk-forward, matriz de confusion, importancia de features y validacion de independencia frente a EMA/RSI/momentum.

Que no esta listo: integracion operativa con Bot A principal, decision economica por clase, politica para casos FAIR y calibracion con resultados reales.

2. Arquitectura de Gaspar

Gaspar es el modulo de calidad de oportunidad. Su pregunta no es "hacia donde va el precio", sino "si existe una propuesta de direccion, este momento tiene calidad suficiente para ejecutarla".

- **Baltasar:** prediccion direccional basada en datos tecnicos. Puede proponer direccion, pero Gaspar no recibe su confianza, probabilidades ni features.
- **Melchor:** riesgo, seguridad y veto operativo. Puede rechazar una entrada aunque Gaspar vote GOOD.
- **Gaspar:** evalua estructura H4/D1, posicion en rango, niveles, sesion, rango disponible y contexto diario.

Flujo: Bot A_sub2 genera snapshots estructurales y temporales -> dataset CSV/JSONL -> entrenamiento Gaspar -> output GOOD | FAIR | POOR con score -> uso futuro por CEO-MAGI junto con los otros magos.

proposed_direction puede ser BUY, SELL o NEUTRAL. En entrenamiento se genera como proxy estructural: D1 bullish y H4 no bearish -> BUY; D1 bearish y H4 no bullish -> SELL; rango o conflicto fuerte -> NEUTRAL. Esto mantiene a Gaspar separado de la prediccion direccional.

3. Dataset auditado de 24 meses

520 / 520 CSV / JSONL sin archivos vacios	297,104 Filas raw CSV + JSONL	148,552 Filas normalizadas sin duplicacion espejo	731 dias Rango temporal 2024-04-12 23:55 UTC a 2026-04-14 23:50 UTC
--	--	--	---

Calidad: **ALTA**. No se detectaron archivos corruptos, schema viejo, duplicados reales, timestamps repetidos con valores distintos ni contenido prohibido. daily_atr_consumed_pct esta dentro de 0..1 y las features criticas no presentan nulos.

Validacion	Resultado
Archivos vacios/corruptos	0
Schema viejo: baltasar_direction / alignment_with_baltasar	No aparece
Schema nuevo: proposed_direction / directional_alignment	Presente
Duplicados exactos y por clave	0 reales tras carga
Gaps grandes no explicables	No detectados
Contenido prohibido EMA/RSI/iMA/iRSI/momentum	No aparece

proposed_direction			directional_alignmnet		
NEUTRAL		102,633 69.1%	neutral		102,633 69.1%
BUY		23,124 15.6%	aligned		45,919 30.9%
SELL		22,795 15.3%	contradictory		0 0.0%

Estructura H4			Estructura D1		
range		106,544 71.7%	range		94,042 63.3%
bearish		22,502 15.1%	bullish		28,163 19.0%
bullish		19,506 13.1%	bearish		26,347 17.7%

Sesiones activas		
asia		43,324 29.2%
new_york		37,173 25.0%
london		30,963 20.8%
overlap		24,809 16.7%
inactive		12,283 8.3%

4. Evolucion de targets v1 -> v4

v1 fue la heurística inicial de cuatro pilares. Fallo por concentrar demasiado la salida en FAIR en el dataset exploratorio, reduciendo contraste operativo.

v2 introdujo guardrails: NEUTRAL nunca puede ser GOOD, rango disponible cero penaliza fuerte y el mercado diario agotado reduce score. Es el baseline actual porque separa bien clases y mantiene F1 alto.

v3 intento suavizar la penalizacion de current_d1_range_vs_atr, pero no redujo la dependencia de esa variable.


v4 reemplaza la penalizacion numerica directa por daily_range_state EARLY/MID/LATE y excluye el continuo del entrenamiento v4. Mejora estabilidad temporal, pero el estado LATE domina la importancia.

Target	GOOD	FAIR	POOR	F1 macro	Accuracy	Walk-forward
v1	4.38%	92.75%	2.87%	0.5603	0.9261	No comparable 24M
v2	11.9%	46.9%	41.2%	0.8912	0.8809	0.8665 ± 0.0220
v3	7.86%	46.74%	45.40%	0.8364	0.8150	No promovido
v4	14.7%	55.1%	30.2%	0.8903	0.8949	0.8816 ± 0.0165

Distribucion target_v2



Distribucion target_v4



5. Resultados del entrenamiento 24M

v2 baseline

0.8912
F1 macro

0.8809
Accuracy


0.8665
Walk-forward mean
std 0.0220

feature continua
Riesgo principal
current_d1_range_vs_atr_capped


Matriz de confusion v2

Real \ Pred	GOOD	FAIR	POOR
GOOD	4,354	205	0
FAIR	523	19,462	913
POOR	0	3,669	15,440


Distribucion real vs predicha v2



Walk-forward v2



Feature importance v2



v4 challenger

0.8903
F1 macro

0.8949
Accuracy


0.8816
Walk-forward mean
std 0.0165

estado discreto
Riesgo principal
daily_range_state_LATE


Matriz de confusion v4

Real \ Pred	GOOD	FAIR	POOR
GOOD	4,739	721	0
FAIR	371	23,535	857
POOR	17	2,719	11,607


Distribucion real vs predicha v4



Walk-forward v4



Feature importance v4



6. Analisis tecnico

Gaspar si aprendio patrones reproducibles: los F1 macro en 24M son altos y la validacion walk-forward no colapsa. El modelo distingue GOOD y POOR con errores principalmente hacia FAIR, que es el comportamiento deseable para un filtro conservador.

No hay colapso de clases. v2 y v4 predicen las tres clases. v2 es mas duro con POOR; v4 mueve mas casos hacia FAIR y mejora accuracy general.

Variables dominantes. En v2 domina current_d1_range_vs_atr_capped con 0.4269. En v4 domina daily_range_state_LATE con 0.3589. Esto confirma que el contexto de agotamiento diario es informativo, pero tambien que el target aun esta muy moldeado por esa logica.

Riesgo de overfitting. Es moderado. La estabilidad walk-forward es buena, especialmente v4, pero el target sigue siendo heuristico. El modelo puede estar aprendiendo la heuristica con alta fidelidad, no necesariamente la rentabilidad real.

Comparacion real v2 vs v4. v2 gana por F1 macro y mantiene mejor separacion conservadora entre GOOD/POOR. v4 gana en accuracy y estabilidad temporal. La diferencia de F1 es minima, pero v4 no elimina dependencia conceptual; la discretiza. Por eso v4 es challenger, no baseline.

7. Conclusion tecnica

El baseline actual debe ser **target_v2**. Es el mejor equilibrio entre separacion, trazabilidad y prudencia operativa. **target_v4** debe conservarse como experimento prioritario para la siguiente ronda porque mejora estabilidad walk-forward, pero requiere validacion economica antes de promocion.

Gaspar hoy es confiable como modulo analitico y de backtesting serio; no es confiable aun como autorizador de trading real porque no ha sido calibrado contra outcomes reales de Bot C.

8. Estado operativo

Uso	Estado	Justificacion
Analisis	Si	Pipeline estable, dataset 24M auditado y metricas consistentes.
Backtesting serio	Si	Hay cobertura temporal suficiente y targets comparables. Debe evaluarse rentabilidad por clase.
Trading real	No	Faltan Bot C, resultados reales, politica para FAIR e integracion segura con CEO-MAGI.

9. Riesgos actuales

- **Target heuristico:** el modelo aprende una definicion disenada, no una verdad economica validada.
- **Dependencia de contexto diario:** v2 depende del continuo; v4 del estado LATE.
- **Ausencia de outcomes reales:** falta confirmar si GOOD mejora expectancy y si POOR evita perdidas.
- **Generalizacion:** validado en EURUSD; requiere expansion controlada por simbolo y regimen.
- **Clase FAIR:** necesita politica clara; hoy es zona de incertidumbre, no autorizacion automatica.

10. Siguientes pasos

1. Integrar en Bot A principal un bloque gaspar_context separado, sin indicadores ni features de Baltasar.
2. Diseñar Bot C para registrar resultado real de cada oportunidad y permitir target supervisado.
3. Validar v2 y v4 con PnL, MFE/MAE, drawdown evitado y expectancy por clase.
4. Definir politica operativa para FAIR: bloqueo, reduccion de tamano, espera de confirmacion o solo logging.
5. Evaluar estabilidad por sesion, estructura D1, direccion propuesta y regimen de volatilidad.
6. Reentrenar con targets calibrados por resultado real antes de conectar Gaspar al CEO-MAGI en modo operativo.